

# Analiza skupa jednoćelijskih transkriptomska mapa ljudskog pankreasa

Jana Živković

Februar, 2026

## 1 Uvod i opis podataka

U okviru projekta analiziran je skup podataka *Jednoćelijske transkriptomske mape ljudskog pankreasa*. Podaci su preuzeti u obliku četiri kompresovana CSV fajla, koji odgovaraju uzorcima četiri različite osobe. Svaki fajl sadrži matricu UMI vrednosti po genima na nivou pojedinačnih ćelija, zajedno sa metapodacima o ćelijama.

Dimenzije podataka su:

- osoba1: 1937 redova i 20128 kolona,
- osoba2: 1724 reda i 20128 kolona,
- osoba3: 3605 redova i 20128 kolona,
- osoba4: 1303 reda i 20128 kolona.

Primećeno je da sve četiri tabele imaju identičan skup naziva kolona. Prve tri kolone su metapodaci i pojavljuju se na početku svake tabele, dok se preostale kolone odnose na gene.

Kolone u svim tabelama počinju sa:

`'Unnamed: 0', 'barcode', 'assigned_cluster'.`

Nakon toga slede kolone koje predstavljaju različite gene, pri čemu su njihove vrednosti celobrojne UMI vrednosti. UMI (Unique Molecular Identifier) predstavlja procenu broja originalnih mRNA molekula određenog gena u jednoj ćeliji.

Analizom tipova podataka utvrđeno je:

- prve tri kolone (`Unnamed: 0`, `barcode`, `assigned_cluster`) su tipa `string`,
- sve preostale kolone (genska ekspresija) su tipa `int64`.

Dodatno je provereno prisustvo nedostajućih vrednosti u svakoj bazi, pri čemu je utvrđeno da **ne postoje nedostajući podaci** ni u jednom od četiri uzorka.

### 1.1 Strukturisanje podataka korišćenjem AnnData objekta

Podaci su učitani u formatu `AnnData` objekat, koji predstavlja standardnu strukturu podataka za analizu jednoćelijskih transkriptomskih podataka u Python-u.

`AnnData` (Annotated Data) je specijalizovana struktura podataka dizajnirana za rad sa visokodimenzionalnim biološkim matricama, posebno u kontekstu jednoćelijske RNA-seq analize.

Matematički, `AnnData` objekat organizuje podatke u sledeću strukturu:

- `X` – glavna matrica podataka dimenzije  $n \times p$ , gde je  $n$  broj ćelija, a  $p$  broj gena. Element  $X_{ij}$  predstavlja UMI broj gena  $j$  u ćeliji  $i$ .
- `obs` – tabela metapodataka po ćelijama (dimenzije  $n \times k$ ), koja može sadržati:
  - barkod ćelije,

- dodeljeni klaster,
  - QC metrike,
  - rezultate klasterovanja ili klasifikacije.
- **var** – tabela metapodataka po genima (dimenzije  $p \times m$ ), npr. informacije o visoko varijabilnim genima, genetskim markerima i sl.
  - **layers** – alternativne reprezentacije iste matrice (npr. sirovi counts, log-transformisani podaci, skalirani podaci).
  - **obs** – matrice redukovane dimenzionalnosti (npr. PCA, UMAP koordinate).

Korišćenje **AnnData** objekta je praktičnije i metodološki opravdano iz više razloga:

1. Jasno razdvajanje ekspresione matrice i metapodataka.
2. Efikasnost memorije. **AnnData** podržava sparse matrice, što je ključno jer je scRNA-seq matrica izrazito retka (veliki broj nula). Ovo značajno smanjuje memorijsku potrošnju.
3. Većina savremenih Python alata za scRNA-seq (Scanpy, scvi-tools, squidpy) očekuje ulaz u formatu **AnnData**. Time se omogućava kompatibilnost sa postojećim metodama za:
  - normalizaciju,
  - selekciju visoko varijabilnih gena,
  - redukciju dimenzionalnosti (PCA, UMAP),
  - klasterovanje (Leiden, Louvain),
  - diferencijalnu ekspresiju.
4. Rezultati pojedinih koraka (npr. PCA koordinate, klusterske oznake) mogu se direktno čuvati unutar objekta bez kreiranja dodatnih struktura.

Pristup podacima se vrši na sledeći način:

- Ekspresiona matrica: `adata.X`
- Metapodaci ćelija: `adata.obs`
- Metapodaci gena: `adata.var`
- Log-transformisani podaci: `adata.layers["log1p"]`
- PCA koordinate: `adata.obsm["X_pca"]`

## 2 Preprocesiranje podataka

### 2.1 Standardizovana kontrola kvaliteta (QC) u scRNA-seq analizi

Kontrola kvaliteta (Quality Control, QC) predstavlja standardni i neizostavni korak u analizi jednoćelijskih RNA-seq podataka. Cilj QC procedure jeste identifikacija i uklanjanje ćelija čija ekspresiona matrica verovatno ne odražava stabilno biološko stanje, već tehničke artefakte (oštećene ćelije, fragmentisane membrane, nedovoljna dubina sekvenciranja, dominacija malog broja gena i sl.).

U literaturi se kao standardne QC metrike izdvajaju sledeće:

1. **total\_counts**. Predstavlja zbir svih UMI vrednosti u jednoj ćeliji:

$$\text{total\_counts}_i = \sum_{j=1}^p X_{ij}.$$

Niske vrednosti mogu ukazivati na nedovoljno sekvenciranje ili oštećene ćelije.

2. **n\_genes\_by\_counts.** Broj gena  $j$  za koje važi  $X_{ij} > 0$ . Čelije sa veoma malim brojem detektovanih gena često su tehnički neadekvatne.

3. **pct\_counts\_mt.**

$$\text{pct\_counts\_mt}_i = \frac{\sum_{j \in MT} X_{ij}}{\text{total\_counts}_i} \times 100.$$

Visok udeo mitohondrijalnih očitavanja često ukazuje na oštećenje ćelijske membrane i početak ćelijske smrti.

4. **pct\_counts\_in\_top\_20\_genes.** Meri koncentraciju ekspresije:

$$\frac{\text{zbir očitavanja 20 najizraženijih gena}}{\text{ukupan broj očitavanja}}.$$

Visoke vrednosti ukazuju da mali broj gena dominira ekspresijom, što može signalizirati tehničke anomalije.

Funkcija

```
sc.pp.calculate_qc_metrics(
    osoba1_adata,
    qc_vars=["mt", "ribo", "hb"],
    inplace=True,
    percent_top=[20],
    log1p=True
)
```

automatski računa QC metrike i dodaje ih u `adata.obs` i `adata.var`.

Parametri znače:

- **qc\_vars=["mt", "ribo", "hb"]** – koristi prethodno definisane logičke maske u `adata.var` da bi izračunala procenat očitavanja za te grupe gena.
- **percent\_top=[20]** – računa procenat očitavanja koji dolazi od 20 najizraženijih gena.
- **log1p=True** – dodatno računa  $\log(1 + x)$  transformacije metrika, specifično za ukupan broj očitavanja (`total_counts`) i broj detektovanih gena (`n_genes_by_counts`)
- **inplace=True** – rezultati se direktno upisuju u objekat.

QC metrike poput ukupnog broja očitavanja (`total_counts`) i broja detektovanih gena (`n_genes_by_counts`) tipično imaju izrazito desno-asimetrične raspodele sa dugim repom i ekstremnim vrednostima, pri čemu su razlike između ćelija često multiplikativne prirode. Primena  $\log(1 + x)$  transformacije omogućava kompresiju velikih vrednosti, približavanje raspodele simetričnom obliku i stabilizaciju disperzije, čime se obezbeđuje pouzdanija i robustnija detekcija outlier ćelija zasnovana na MAD kriterijumu.

Za identifikaciju ekstremnih ćelija korišćen je kriterijum zasnovan na median absolute deviation (MAD).

Za posmatranu metriku  $M$  definiše se:

$$\text{MAD} = \text{median}(|M_i - \text{median}(M)|).$$

Ćelija se označava kao outlier ako:

$$M_i < \text{median}(M) - k \cdot \text{MAD} \quad \text{ili} \quad M_i > \text{median}(M) + k \cdot \text{MAD},$$

gde je  $k$  broj dozvoljenih odstupanja (u radu korišćeno  $k = 5$ ).

Prednost MAD kriterijuma u odnosu na standardnu devijaciju jeste njegova robustnost na ekstremne vrednosti, što je posebno važno kod visokodimenzionalnih bioloških podataka.

Analiza distribucije QC metrika pokazala je da ne postoje ćelije sa ekstremno niskim brojem detektovanih gena niti sa izrazito malom dubinom sekvenciranja. Minimalan broj gena po ćeliji iznosio

je 819, što je znatno iznad tipičnih pragova koji se koriste za filtriranje sirovih scRNA-seq podataka (200–500 gena).

Takođe, u ekspresionoj matrici nisu identifikovani mitohondrijalni geni, što sugerise da su oni verovatno uklonjeni u prethodnim fazama obrade podataka.

Mali broj detektovanih outlier ćelija prema robustnom MAD kriterijumu dodatno ukazuje na to da je skup podataka verovatno već prošao inicijalne korake kontrole kvaliteta pre javnog objavljivanja. U tom smislu, sprovedeni QC u ovom radu predstavlja verifikaciju kvaliteta već procesiranog skupa podataka.

## 2.2 Normalizacija

Nakon kontrole kvaliteta sprovedena je standardna normalizacija ekspresionih podataka korišćenjem funkcije `sc.pp.normalize_total` sa parametrom `target_sum=104`. Ovim postupkom svaka ćelija se skalira tako da njen ukupan broj očitavanja bude jednak 10 000, čime se eliminišu tehničke razlike u dubini sekvenciranja između ćelija.

Matematički, vrednosti se transformišu kao:

$$X_{ij}^{norm} = \frac{X_{ij}}{\sum_j X_{ij}} \cdot 10^4.$$

Nakon skaliranja primenjena je  $\log(1+x)$  transformacija pomoću funkcije `sc.pp.log1p`, čime se redukuje asimetrija raspodele i stabilizuje varijansa ekspresionih vrednosti. Ova transformacija smanjuje uticaj ekstremno visoko izraženih gena i čini podatke pogodnijim za metode redukcije dimenzionalnosti i klasterovanja.

Pred normalizacije sam sacuvala i sirove podatke, kao i napravila kopiju normalizovanih podataka.

## 2.3 Selekcija informativnih gena

U jednoćelijskim RNA-seq podacima broj gena ( $p \approx 20\,000$ ) značajno prevazilazi broj ćelija, dok veliki deo gena pokazuje nisku ili gotovo konstantnu ekspresiju kroz sve ćelije. Uključivanje svih gena u dalju analizu uvodi šum i negativno utiče na stabilnost PCA dekompozicije i klasterovanja.

Zbog toga se primenjuje selekcija visoko varijabilnih gena (Highly Variable Genes, HVG), čiji je cilj izdvajanje gena koji nose najviše informacija o heterogenosti ćelijskih populacija.

Za svaki gen  $j$  računa se srednja ekspresija:

$$\mu_j = \frac{1}{n} \sum_{i=1}^n X_{ij},$$

i disperzija:

$$\sigma_j^2 = \frac{1}{n-1} \sum_{i=1}^n (X_{ij} - \mu_j)^2,$$

gde  $X_{ij}$  predstavlja log-normalizovanu ekspresiju gena  $j$  u ćeliji  $i$ , a  $n$  je broj ćelija.

Kod RNA-seq podataka postoji inherentna zavisnost između srednje vrednosti i disperzije: geni sa većom srednjom ekspresijom prirodno imaju veću disperziju. Zbog toga selekcija gena isključivo na osnovu disperzije favorizuje visoko eksprimirane gene, a ne nužno biološki najinformativnije.

Seurat metod rešava ovaj problem na sledeći način:

1. Geni se grupišu prema sličnoj srednjoj ekspresiji.
2. Unutar svake grupe procenjuje se očekivana disperzija kao funkcija srednje vrednosti.
3. Za svaki gen računa se normalizovana disperzija:

$$\text{dispersions\_norm}_j = \frac{\sigma_j^2 - E(\sigma^2 | \mu_j)}{D(\sigma^2 | \mu_j)}.$$

Ova standardizacija omogućava poređenje varijabilnosti gena nezavisno od njihove prosečne ekspresije.

U radu je odabrano  $n_{\text{top}} = 4000$  gena sa najvećom normalizovanom disperzijom, čime se balansira između zadržavanja biološke informacije i redukcije šuma.

Pošto podaci potiču iz više uzoraka (H1–H4), korišćen je parametar `batch_key="batch"`, koji omogućava:

1. procenu varijabilnosti unutar svakog uzorka zasebno,
2. identifikaciju gena koji su konzistentno varijabilni kroz više batch-eva,
3. smanjenje uticaja tehničkih razlika između uzoraka.

Bez ovog parametra, mogli bi biti selektovani geni koji reflektuju razlike između uzoraka, a ne istinsku biološku heterogenost ćelija.

Poziv funkcije automatski dodaje sledeće kolone u `adata.var`:

- `means` – srednja ekspresija po genu,
- `dispersions` – sirova disperzija,
- `dispersions_norm` – normalizovana disperzija,
- `highly_variable` – logička maska za selektovane gene,
- `highly_variable_rank` – rang prema varijabilnosti,
- `highly_variable_nbatches` – broj batch-eva u kojima je gen označen kao varijabilan.


Na ovaj način, HVG selekcija ne menja ekspresionu matricu, već označava informativne gene, koji se zatim koriste u daljoj redukciji dimenzionalnosti.

### 3 Smanjenje dimenzionalnosti i vizualizacija

Nakon selekcije gena, primenjena je redukcija dimenzionalnosti metodom PCA korišćenjem funkcije `sc.pp.pca` uz opciju `use_highly_variable=True`, čime se PCA računa isključivo na prethodno izdvojenim HVG genima. Dobijene PCA koordinate ćelija sačuvane su u `adata.obsm["X_pca"]`, gde se nalazi prvih 50 glavnih komponenti.

Za nelinearnu vizualizaciju ćelija korišćena je t-SNE metoda implementirana funkcijom `sc.tl.tsne`. Kako bi se smanjio šum i ubrzalo računanje, t-SNE je primenjen nad PCA reprezentacijom podataka (`use_rep="X_pca"`). Dobijene 2D koordinate sačuvane su u `adata.obsm["X_tsne"]`.


t-SNE projekcija je potom vizualizovana bojenjem ćelija prema dubini sekvenciranja (`total_counts`), pripadnosti uzorku (`batch`) i postojećim klsterskim oznakama (`assigned_cluster`), kako bi se procenio potencijalni uticaj tehničkih faktora i konzistentnost bioloških grupa.



Na osnovu PCA reprezentacije konstruisan je graf k-najbližih suseda korišćenjem funkcije `sc.pp.neighbors`. Ovaj graf predstavlja osnovu za dalju nelinearnu redukciju dimenzionalnosti i klasterovanje.

UMAP projekcija je zatim izračunata funkcijom `sc.tl.umap`, pri čemu se optimizuje očuvanje lokalne geometrijske strukture podataka u dvodimenzionalnom prostoru. Dobijene koordinate sačuvane su u `adata.obsm["X_umap"]`.

UMAP mapa je vizualizovana bojenjem ćelija prema dubini sekvenciranja, uzorku porekla i postojećim klsterskim oznakama radi procene tehničkih i bioloških faktora koji utiču na strukturu podataka.



Batch efekat je procenjen vizuelno kroz PCA/UMAP projekcije obojene prema uzorku (`batch`). Kako nije došlo do uočljivog grupisanja ćelija prema uzorku, procenjeno je da primena batch korekcije nije potrebna.

## 4 Pravila pridruživanja i mreža gena

U cilju identifikacije potencijalnih funkcionalnih odnosa između gena primenjena je analiza pravila pridruživanja. Pošto su metode za otkrivanje pravila razvijene za transakcione podatke, ekspresiona matrica gena transformisana je u binarni oblik.

Najpre je izvršena selekcija podskupa gena kako bi se smanjila dimenzionalnost i izbegla kombinatorna eksplozija kandidata za pravila. Izabrano je 100 gena sa najvećom varijabilnošću. Za svaku ćeliju formiran je binarni vektor:

$$x_{ij} = \begin{cases} 1 & \text{ako je ekspresija gena } j \text{ u ćeliji } i > 0 \\ 0 & \text{inače} \end{cases}$$

Tako se svaka ćelija može posmatrati kao transakcija koja sadrži skup aktivnih gena.

Za nalaženje pravila korišćen je **FP-Growth algoritam**, koji omogućava efikasno pronalaženje čestih skupova bez generisanja svih kandidata. Za selekciju pravila korišćeni su standardni kriterijumi:

- minimalna podrška (support)
- minimalna pouzdanost (confidence)
- lift kao mera jačine pridruživanja

Pravila su filtrirana tako da sadrže samo parove gena, čime je omogućena konstrukcija mreže koekspresije.

### 4.1 Konstrukcija mreže gena

Na osnovu izdvojenih pravila konstruisan je graf gena. Svaki gen predstavlja čvor, dok pravilo oblika

$$A \Rightarrow B$$

indukuje ivicu između gena  $A$  i  $B$ .  
Graf je definisan kao:

$$G = (V, E)$$

gde je:

- $V$  skup gena
- $E$  skup ivica između gena koji učestvuju u pravilima

Težina ivice određena je vrednošću **lift** metrike, koja kvantifikuje jačinu statističke zavisnosti između dva gena.

U implementaciji je korišćena biblioteka **networkx**, pri čemu je graf konstruisan agregacijom svih pravila. U slučaju da postoji više pravila između istog para gena, zadržano je pravilo sa najvećim lift-om.

## 4.2 Klasterovanje gena

Za identifikaciju funkcionalnih modula gena izvršena je klasterovanje na nivou mreže gena. Umesto klasterovanja ćelija, fokus je stavljen na identifikaciju grupa međusobno povezanih gena.

Za detekciju zajednica u mreži primenjen je algoritam maksimizacije modularnosti (greedy modularity communities). Ovak algoritam pronalazi particiju grafa koja maksimizuje modularnost:

$$Q = \frac{1}{2m} \sum_{ij} \left( A_{ij} - \frac{k_i k_j}{2m} \right) \delta(c_i, c_j)$$

gde je  $A_{ij}$  matrica susedstva,  $k_i$  stepen čvora, a  $c_i$  oznaka zajednice kojoj čvor pripada.

Rezultat ovog postupka predstavlja skup modula gena koji potencijalno odgovaraju koregacionim ili funkcionalnim genetskim grupama. Ovakav pristup omogućava dublji uvid u strukturu podataka jer analizira relacije između gena.

## 5 Klasterovanje ćelija

Klasterovanje ćelija izvršeno je nad PCA reprezentacijom podataka sa 50 komponenti. Primenjene su sledeće metode:

- K-means
- Spektralno klasterovanje
- Gaussian Mixture Model
- Leiden algoritam
- HDBSCAN

Implementacije su realizovane u Python biblioteci **scikit-learn** i paketu **scanpy**. Za centroidne i parametarske metode (K-means, GMM, spektralno) broj klastera variran je u opsegu  $k \in [6, 12]$ , dok je kod Leiden algoritma korišćena rezolucija kao hiperparametar. Kvalitet podele procenjen je *silhouette* merom.

### 5.1 Poređenje metoda klasterovanja

Tokom analize uočeno je da različite metode daju značajno različite strukture klastera, kao i da *silhouette* mera ne mora verno odražavati biološku ispravnost podele.

Kod K-means algoritma pretpostavlja se postojanje sfernih klastera približno jednake veličine. Iako ova pretpostavka u visoko-dimenzionalnim biološkim podacima često nije u potpunosti ispunjena, K-means je uspeo da jasnije razdvoji određene biološki relevantne populacije ćelija, posebno alfa, beta, gama i delta ćelije pankreasa.

HDBSCAN, kao gustinski zasnovan algoritam, postigao je najvišu *silhouette* vrednost među svim metodama. Međutim, ova vrednost je obmanjujuća: *silhouette* za HDBSCAN računata je isključivo nad ćelijama dodeljenim klasterima, dok su ćelije označene kao šum (oznaka  $-1$ ) izostavljene iz proračuna. Visoka vrednost stoga odražava kompaktnost pouzdanih jezgara klastera, a ne kvalitet podele svih ćelija. Vizuelnom analizom (UMAP i t-SNE projekcije) utvrđeno je da HDBSCAN ne razdvaja jasno endokrine populacije, već ih spaja ili granične ćelije tretira kao šum, iako su one u bazi anotirane kao različiti tipovi.

Iako je globalna *silhouette* vrednost za K-means niža nego za HDBSCAN, vizuelna analiza pokazuje da K-means bolje rekonstruiše strukturu alfa, beta, gama i delta ćelija. Ovo ukazuje da *silhouette* mera, posmatrana izolovano, predstavlja nepouzdan kriterijum za ovaj skup podataka.

Ovakva razlika u ponašanju algoritama sugerise da se podaci verovatno nalaze na kompleksnoj, nelinearnoj mnogostrukosti u prostoru ekspresije gena, gde različiti algoritmi naglašavaju različite aspekte strukture podataka.

## 6 Klasifikacija

Zadatak klasifikacije formulisan je kao predikcija oznake klastera (`assigned_cluster`) na osnovu ekspresije gena.

Korišćene su sledeće metode:

- Random Forest
- Support Vector Machine
- Gaussian Naive Bayes
- XGBoost
- LightGBM

Implementacije modela realizovane su u biblioteci `scikit-learn`, dok su XGBoost i LightGBM korišćeni kroz njihove Python implementacije.

### 6.1 Unakrsna validacija

Ocena modela izvršena je korišćenjem **unakrsne validacije** sa  $k = 5$ .

Kako bi se izbeglo curenje informacija, redukcija dimenzionalnosti pomoću PCA izvršena je isključivo na trening skupu u svakom koraku, nakon čega su iste komponente primenjene na test deo. Ovakav postupak obezbeđuje korektnu procenu generalizacione greške modela.

Za svaki model izračunate su sledeće vrednosti:

| Model         | Accuracy          | Macro F1          |
|---------------|-------------------|-------------------|
| SVM           | $0.989 \pm 0.003$ | $0.956 \pm 0.029$ |
| LightGBM      | $0.987 \pm 0.004$ | $0.946 \pm 0.035$ |
| XGBoost       | $0.988 \pm 0.004$ | $0.944 \pm 0.040$ |
| Naive Bayes   | $0.978 \pm 0.004$ | $0.934 \pm 0.037$ |
| Random Forest | $0.986 \pm 0.004$ | $0.909 \pm 0.053$ |

Table 1: Rezultati petostruke stratifikovane kros-validacije za klasifikacione modele u PCA prostoru sa 50 komponenti. Prikazane su srednje vrednosti i standardne devijacije.

Najbolje rezultate ostvario je SVM model, sa prosečnom tačnošću od 0.989 i prosečnom macro F1 merom od 0.956. Ovaj rezultat ukazuje da su klase veoma dobro razdvajive u PCA prostoru.

LightGBM i XGBoost takođe postižu veoma visoke performanse. To sugerise da su boosting metode vrlo konkurentne, ali da SVM daje najstabilniji kompromis između ukupne tačnosti i ravnomerne uspešnosti po klasama.